Факультет социально-экономических и компьютерных наук

Кафедра информационных технологий в бизнесе

Пермь
2026

Задание 6

Работа с текстовыми данными (классификация текстов)

Шаг1: Базовая часть (полное выполнение — 8 баллов)

1.1) Загрузите и подготовьте данные из файла Literature.csv, SocialMedia.csv или ESG.csv. Проведите токенизацию и базовую предобработку текста: приведите все символы к одному регистру, удалите знаки препинания, специальные символы, стоп слова. Проведите **стемминг**.
1.2) Используйте метод **Bag of Words (Мешок слов)** для преобразования текстов в числовые векторы. Разбейте полученные данные на обучающую и тестовую выборки в соотношении 80/20.
1.3) Выберите **3 модели** из изученных ранее и обучите их на подготовленных данных для верной идентификации одного из имеющихся классов (решайте задачу как задачу бинарной классификации), примените известные вам методы повышения качества модеелй.
1.4) Сравните качество полученных моделей по метрикам Accuracy, F1, Precision, Recall, а также визуализируйте ROC кривые для всех моделей на одном графике и сравните их.
1.5) Выполните **лемматизацию** и решите задачу классификации еще раз. Сравните полученные результаты используя указанные метрики.

Дополнительная к базовой часть :

Шаг 2: +1 балл
2.1) Соберите собственный файл данных содержащий текстовые фрагменты и их разметку (например, тип текста, авторство, тема которой посвящен текст, спам или не спам, токсичный или не токсичный текст и т.п.). С этим же файлом проделайте операции шага 1.
2.2) При подготовке входных данных для методов классификации используйте метод **TF-IDF** и повторите решение задачи классификации.
2.3) Сравните полученные результаты используя метрики качества с результатами полученными при выполнении шага 1. Объясните с чем связаны отличия в полученных результатах.

Шаг 3: еще +1 балл (итого +2 балла к базовой части)
3.1) При подготовке входных данных для методов классификации используйте метод **Word2Vec** и повторите решение задачи классификации.
3.2) При подготовке входных данных для методов классификации используйте частеречную разметку и повторите решение задачи классификации.
3.3) Сравните результаты полученные на данном шаге с результатами полученными на предыдущих шагах.

Literature.csv — фрагменты художественных текстов с авторством, необходимо решить задачу определения авторства
SocialMedia.csv — посты в социальной сети с разметкой по типам сообщений, необходимо решить задачу классификации сообщений по их типам
ESG.csv — разметка текстов по темам обсуждаемым в них для ESG анализа

Рекомендуемая библиотека для выполнения задания spacyR

```
library(spacyr)
#install.packages("spacyr")
#spacy_install()
#spacy_initialize(model = "en_core_web_sm")
spacy_initialize(model = "ru_core_news_lg")
#python3 -m spacy download ru_core_news_lg



data3_1<-read.csv("esenin-2.csv", header =T, sep = ",")
data3_2<-read.csv("random-2.csv", header =T, sep = ",")
data3_1<-cbind(data3_1,class=1)
data3_2<-cbind(data3_2,class=0)
data3<-rbind(data3_1,data3_2)

parsed <- spacy_parse(data3$poem)

f<-data.frame(
  Adj=sum(which(parsed$pos == "ADJ"&parsed$doc_id=="text1"))/sum(parsed$pos == "ADJ"&parsed$doc_id=="text1"),
  Adj_col=sum(parsed$pos == "ADJ"&parsed$doc_id=="text1"),
  Adp=sum(which(parsed$pos == "ADP"&parsed$doc_id=="text1"))/sum(parsed$pos == "ADP"&parsed$doc_id=="text1"),
  Adp_col=sum(parsed$pos == "ADP"&parsed$doc_id=="text1"),
  Adv=sum(which(parsed$pos == "ADV"&parsed$doc_id=="text1"))/sum(parsed$pos == "ADV"&parsed$doc_id=="text1"),

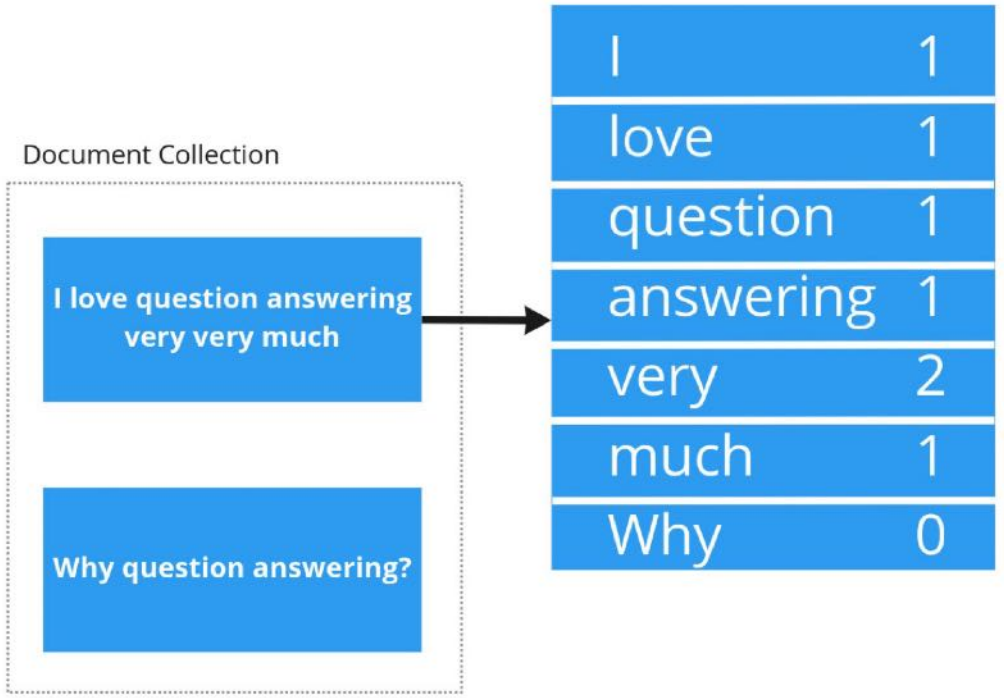
...
```

Анализ текстов (Токенизация? Лемматизация? Стемминг?)

- Токенизация – разделение текста на токены (слова, подслова, Byte Pair Encoding (BPE));
- Удаление стоп слов (шумовых слов) – но, как, или … (англ. but, how, or …);
- Удаление специальных символов – ! @ # $ %;
- Лемматизация – "changing" -> " change»;
- Стемминг – "changing" -> "chang".

Анализ текстов (Bag of Words)

Bag of words — упрощенное представление текста, которое используется в обработке естественных языков и информационном поиске. В этой модели текст (одно предложение или весь документ) представляется в виде мешка (мультимножества) его слов без какого-либо учета грамматики и порядка слов, но с сохранением информации об их количестве.



Подготовка данных для обучения модели с использованием Bag of Words

Токены из всех текстов

	Токен 1	**Токен 2**	**…**	**Метка класса**
Текст 1	[Число токенов 1 в тексте 1]	[Число токенов 2 в тексте 1]	…	
Текст 2	[Число токенов 1 в тексте 2]	[Число токенов 2 в тексте 2]	…	
…	…	…	…	

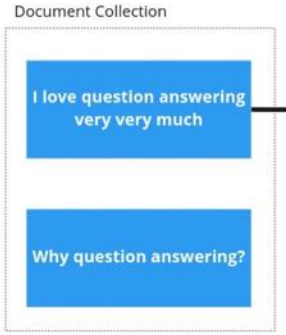
Анализ текстов (Term Frequency - Inverse Document Frequency (TF-IDF))

TF-IDF — статистическая мера, используемая для оценки важности слова в контексте документа.

TF (*term frequency* — частота слова) — отношение числа вхождений некоторого слова к общему числу слов документа.

$$TF_t = \frac{n_t}{\sum_k n_k},$$

где n_t - число вхождений слова t, k - число уникальных слов.



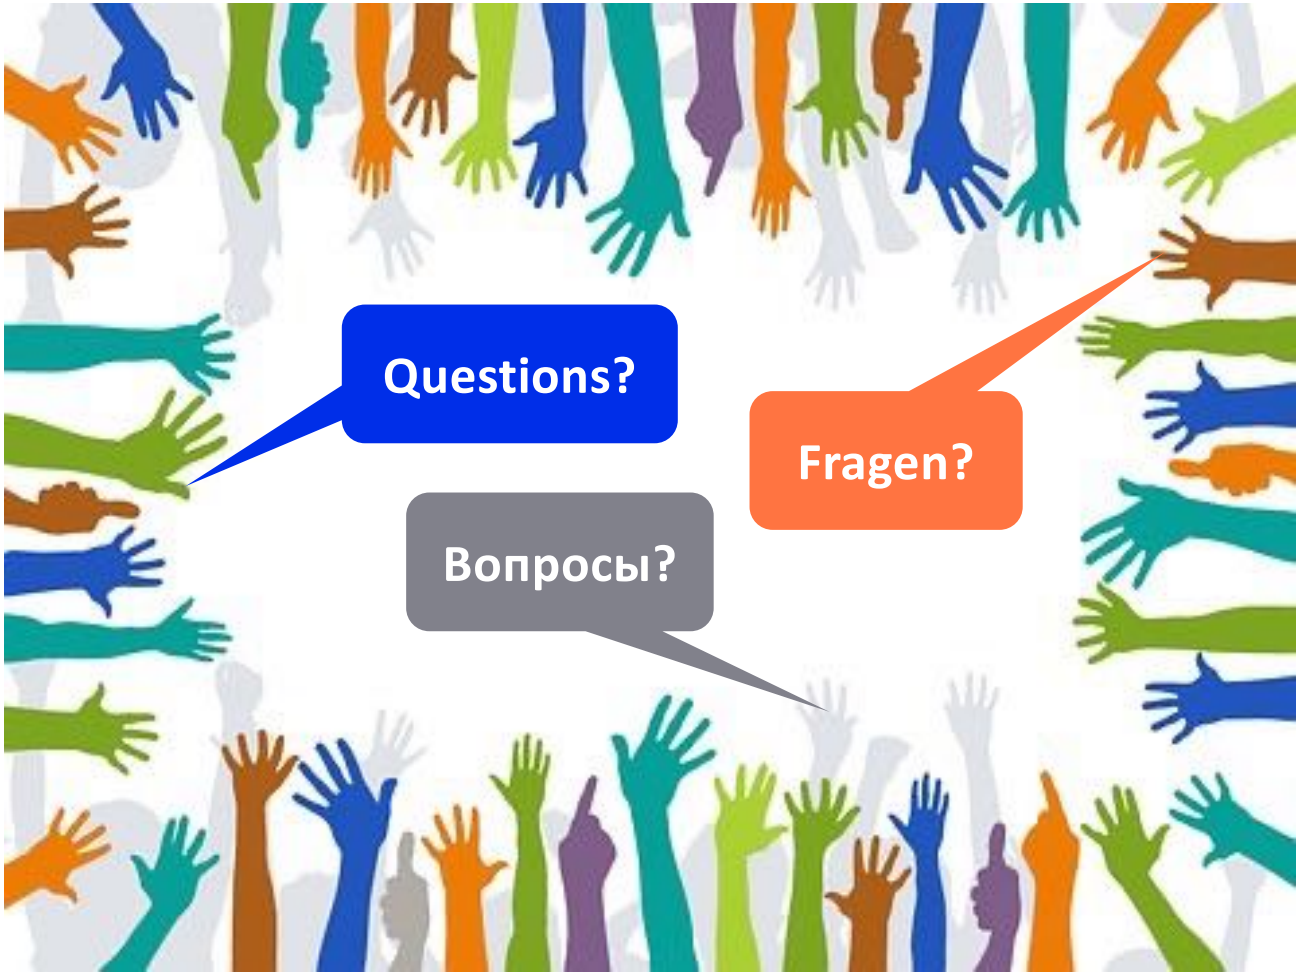
	TF	IDF	TFxIDF
I	1/7	log(2/1)	0.099
love	1/7	log(2/1)	0.099
question	1/7	log(2/2)	0.0
answering	1/7	log(2/2)	0.0
very	2/7	log(2/1)	0.198
much	1/7	log(2/1)	0.099
Why	0/7	log(2/1)	0.0

IDF (inverse document frequency — обратная частота документа) — инверсия частоты, с которой некоторое слово встречается в документах коллекции. Учёт IDF уменьшает вес широкоупотребительных слов. Для каждого уникального слова в пределах конкретной коллекции документов существует только одно значение IDF.

$$IDF = \log\left(\frac{|D|}{|d_i \in D | t \in d_i|}\right)$$

Где D - число документов в коллекции, $|d_i \in D | t \in d_i|$ - число документов из коллекции D в которых встречается слово t.

!!! Большой вес в TF-IDF получат слова с высокой частотой в пределах конкретного документа и с низкой частотой употреблений в других документах.


Questions?
Fragen?
Вопросы?