Факультет социально-экономических и компьютерных наук

Кафедра информационных технологий в бизнесе

Пермь
2026

Задание 7

Работа с текстовыми данными (вопросно-ответные системы)

(Information Retrieval-based Question Answering (IR-based))

Шаг1: Базовая часть (полное выполнение — 8 баллов)

1.1) Создайте свой собственный набор данных (базу знаний) в формате "вопрос - ответ", состоящий минимум из **15 пар**. Вопросы должны быть тематически связаны (например, «Частые вопросы о библиотеке», «Информация о курсах», «Правила поведения», «Как поступить в магистратуру ВШЭ», «Правила внутреннего распорядка вуза» и т.п.).

Пример пары:
Вопрос: "Каков ваш график работы?»
Ответ: "Мы работаем с понедельника по пятницу с 9:00 до 18:00."

1.2) Выполните предобработку (приведение к одному регистру, удаление стоп-слов, лемматизацию/стемминг (на выбор), токенизацию).
1.3) Используйте метод **Bag of Words (Мешок слов)** для преобразования текстов в числовые векторы.
1.4) Реализуйте алгоритм который по заданному вопросу будет проверять сходство с вопросами из базы знаний, выбирать наиболее близкий и выдавать соответствующий ему ответ. Для проверки сходства используйте сходство Жаккара, косинусное расстояние и корреляцию.
1.5) Подготовте не менее 10 вопросов ответы на которые есть в подготовленной базе вопросов-ответов и не менее 5 вопросов ответов на которые нет.
1.6) Соберите статистику и проведите сопоставительный анализ по заданным вопросам и полученным ответам при использовании разных мер сходства. Для этого постройте таблицу

| Вопрос | Правильный ответ | Ответ системы | Метрика 1 (Жаккар) | Метрика 2 (Косинус) | Метрика 3 (Корреляция Пирсона) |

1.7) Сделайте выводы о том какие меры сходства дают лучший результат и объясните почему так происходит по вашему мнению. Объясните, почему косинусное расстояние лучше работает на длинных текстах, а Жаккар — на коротких, учитывая, что Жаккар учитывает только бинарное вхождение (есть/нет), а косинус — частоту (TF-IDF)

Дополнительная к базовой часть :

Шаг 2: +1 балл

2.1) Используйте для преобразования текстов в числовые вектора TF-IDF.
2.2) Дополните базу знаний близкими вопросами/инвариантными формулировками вопросов, инвариантными ответами на вопросы.
2.3) Доработайте ваш код таким образом, чтобы задавать вопросы и получать ответы можно было в режиме диалога, система использовала порог чувствительности и опционально выдавала или все возможные ответы с учетом порога чувствительности или по запросу пользователь один случайный из множества сформированного множества ответов.
2.4) Сравните результаты базовой части (Bag of Words) и дополнительной (TF-IDF). Сделайте вывод о том значимость каких слов TF-IDF занизил (например, частые предлоги), а какие повысил (уникальные термины), и как это повлияло на ранжирование ответов.
2.5) Модернизируйте работу алгоритма таким образом, чтобы он искал соответствие с использованием коэффициента Спирмена. Сделайте выводы об изменении в качестве работы по поиску ответов на вопросы.

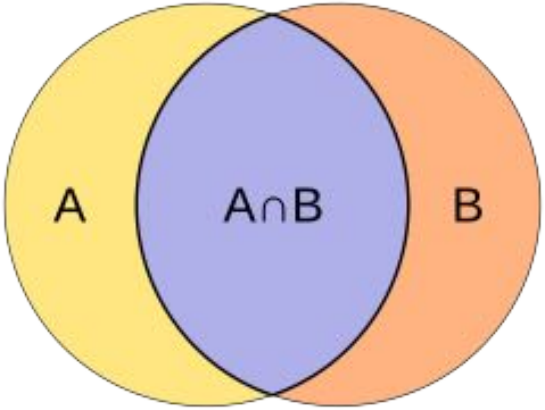
Шаг 3: еще +1 балл (итого +2 балла к базовой части)

3.1) Реализуйте механизм обучения системы который позволит добавлять новые вопросы и ответы, а также дополнительные варианты ответов к уже существующим.
3.2) Реализуйте механизм, который **автоматически выбирает оптимальную метрику сходства** для конкретного вопроса на основе длины входного вопроса (короткие vs длинные запросы) и «разброса» схожести (например, если все метрики дают разные результаты).
3.3) Введите минимальные значения для метрик и в случае если на заданный вопрос получаемые значения меньше этих порогов то сообщать об отсутствии ответа на задаваемый вопрос.
3.4) Реализуйте автоматическую оценку качества работы бота по метрикам (**Accuracy** (точность) — процент полностью правильных ответов, **Top-3 accuracy** — процент случаев, когда правильный ответ есть среди 3 наиболее похожих, **Precision/Recall** — для бинарной классификации «ответ корректен/не корректен»).
3.5) Оцените работу всех заданий по оценке качества с использованием предложенных метрик и постройте сводную таблицу с итоговыми метриками для всех методов и выберите лучший подход с обоснованием

Коэффициент Жаккара

Мера Жаккара (*коэффициент флористической общности*) — бинарная мера сходства, предложенная Полем Жаккаром в 1901 году:

$$K_J = \frac{A}{A + B - C}$$



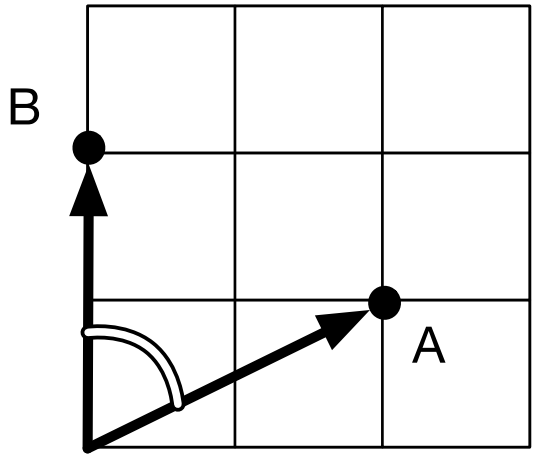
где A — количество токенов первого текста, B — количество токенов второго текста, $C = (A \cap B)$ — количество токенов, общих для первого и второго текста.

Мера работает с множествами токенов и не учитывает порядок слов и их частоту (важно только наличие).

Косинусное расстояние

$$S_{ij} = 1 - cos(B, A) = 1 - \frac{A \cdot B}{\|A\| \cdot \|B\|},$$

где A и B – вектора соответствующие текстам, $A \cdot B$ – скалярное произведение векторов, $\|A\|, \|B\|$– евклидова норма (длина вектора).

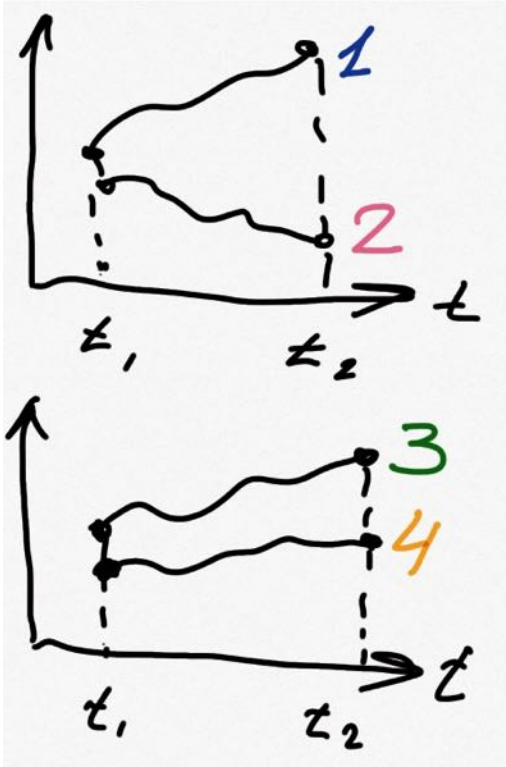


Корреляция

Изучение связей между переменными, интересует исследователя с точки зрения отражения возможных причинно-следственных отношений.

Корреляционный анализ – статистический метод, позволяющий с использованием коэффициентов корреляции определить, существует ли зависимость между переменными и насколько она сильна.

Коэффициент корреляции – двумерная описательная статистика, количественная мера взаимосвязи (совместной изменчивости) двух переменных.



Корреляция (коэффициент корреляции Пирсона, r - коэффициент)

$$r = \frac{cov(X,Y)}{\sqrt{var(X) \cdot var(Y)}} = \frac{cov(X,Y)}{\sigma_X \cdot \sigma_Y} = \frac{\sum_{i=1}^{n}(x_i - x)(y_i - y)}{\sqrt{(\sum_{i=1}^{n}(x_i - x)^2 \cdot \sum_{i=1}^{n}(y_i - y)^2}}$$

σ – среднеквадратичное отклонение, $x = \frac{1}{n}\sum_{i=1}^{n} x_i$, $y = \frac{1}{n}\sum_{i=1}^{n} y_i$.

Получаемое значение будет лежать в диапазоне $-1 \leq r \leq 1$:

$r > 0$ — позитивная корреляция;
$r < 0$— негативная корреляция;
$r = 0$ — отсутствие корреляции;

$|r| \leq 0{,}5$ — слабая корреляция;
$0{,}5 < |r| \leq 0{,}8$ — средняя корреляция;
$0{,}8 < |r|$ — сильная корреляция.

Коэффициент корреляции r - Пирсона оценивает только линейную связь переменных. Нелинейную связь данный коэффициент выявить не может.

Коэффициент корреляции Пирсона очень чувствителен к выбросам.

Корреляция не подразумевает наличия причинно-следственной связи между переменными.

!!! Когда вес слова увеличивается, вес ответа тоже увеличивается

!!! Корреляция Пирсона чувствительна к выбросам, поэтому для текстовых векторов лучше использовать ранговые корреляции (Спирмен/ Кендалл)

Ранговая корреляция (коэффициент ранговой корреляции Кендалла, τ - коэффициент)

Применяется для выявления взаимосвязи между количественными или качественными показателями, если их можно ранжировать. Значения показателя X выставляют в порядке возрастания и присваивают им ранги.
Ранжируют значения показателя Y и рассчитывают коэффициент корреляции

$$\tau = \frac{2 \cdot S}{n(n-1)},$$

где $S = P - Q$, P— суммарное число наблюдений, следующих за текущими наблюдениями с большим значением рангов Y, Q - суммарное число наблюдений, следующих за текущими наблюдениями с меньшим значением рангов Y.
Равные ранги не учитываются!

Если исследуемые данные повторяются (имеют одинаковые ранги), то в расчетах используется скорректированный коэффициент корреляции Кендалла:

$$\tau = \frac{S}{\sqrt{[\frac{n(n-1}{2} - U_x][\frac{n(n-1}{2} - U_y]}},$$

где $U_x = \frac{\sum t(t-1)}{2}$, $U_y = \frac{\sum t(t-1)}{2}$, t - число связанных рангов в ряду X и Y соответственно.

!!! Для малых выборок

Ранговая корреляция (коэффициент ранговой корреляции Спирмена, ρ- коэффициент)

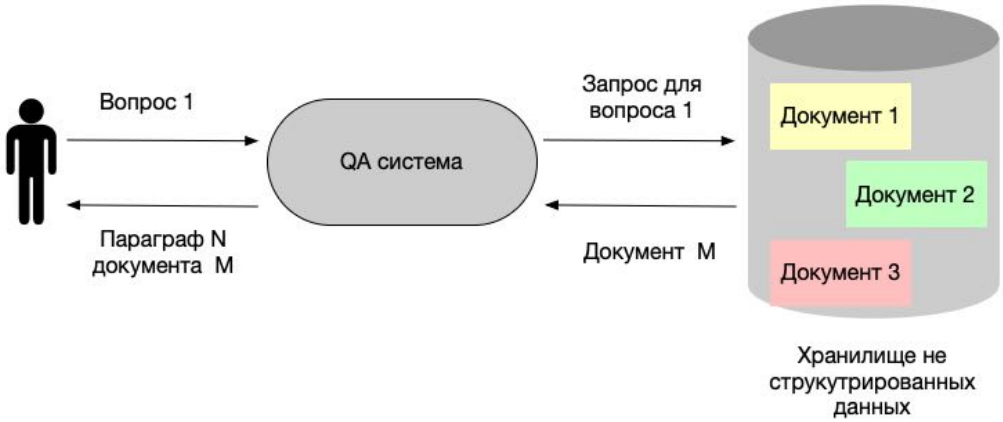
Интерпретируется аналогично коэффициенту корреляции Пирсона и может принимать значения в таком же диапазоне [–1;+1]

$$\rho = 1 - \frac{6 \cdot \sum d_i^2}{n \cdot (n^2 - 1)}$$

Степень зависимости двух случайных величин (признаков) X и Y может характеризоваться на основе анализа получаемых результатов $(X_1, Y_1), \dots, (X_n, Y_n)$. Каждому показателю X и Y присваивается ранг. Ранги значений X расположены в естественном порядке $i = 1,2, \dots, n$. Ранг Y записывается как R_i и соответствует рангу той пары (X, Y), для которой ранг X равен i. На основе полученных рангов X_i и Y_i рассчитываются их разности d_i.

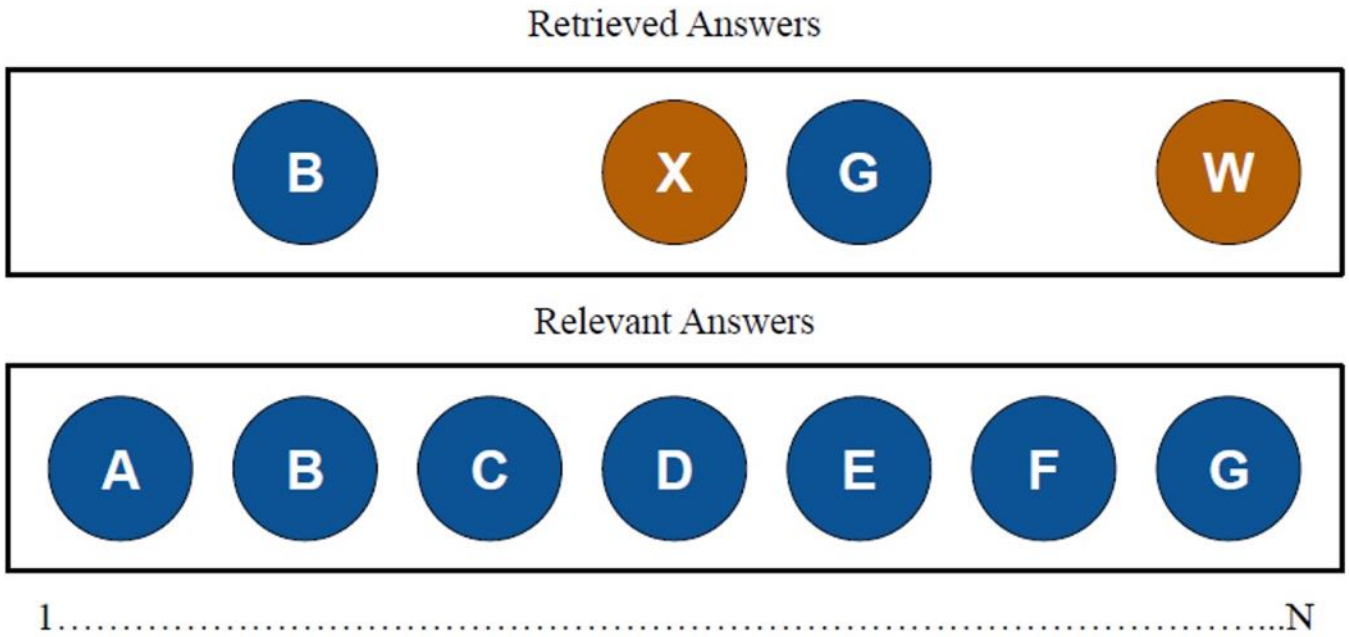
!!! Позволяет оценить, насколько совпадают «порядки» слов в запросе и ответе

Принцип работы IR вопросно-ответной системы (Information Retrieval-based Question Answering (IR-based))

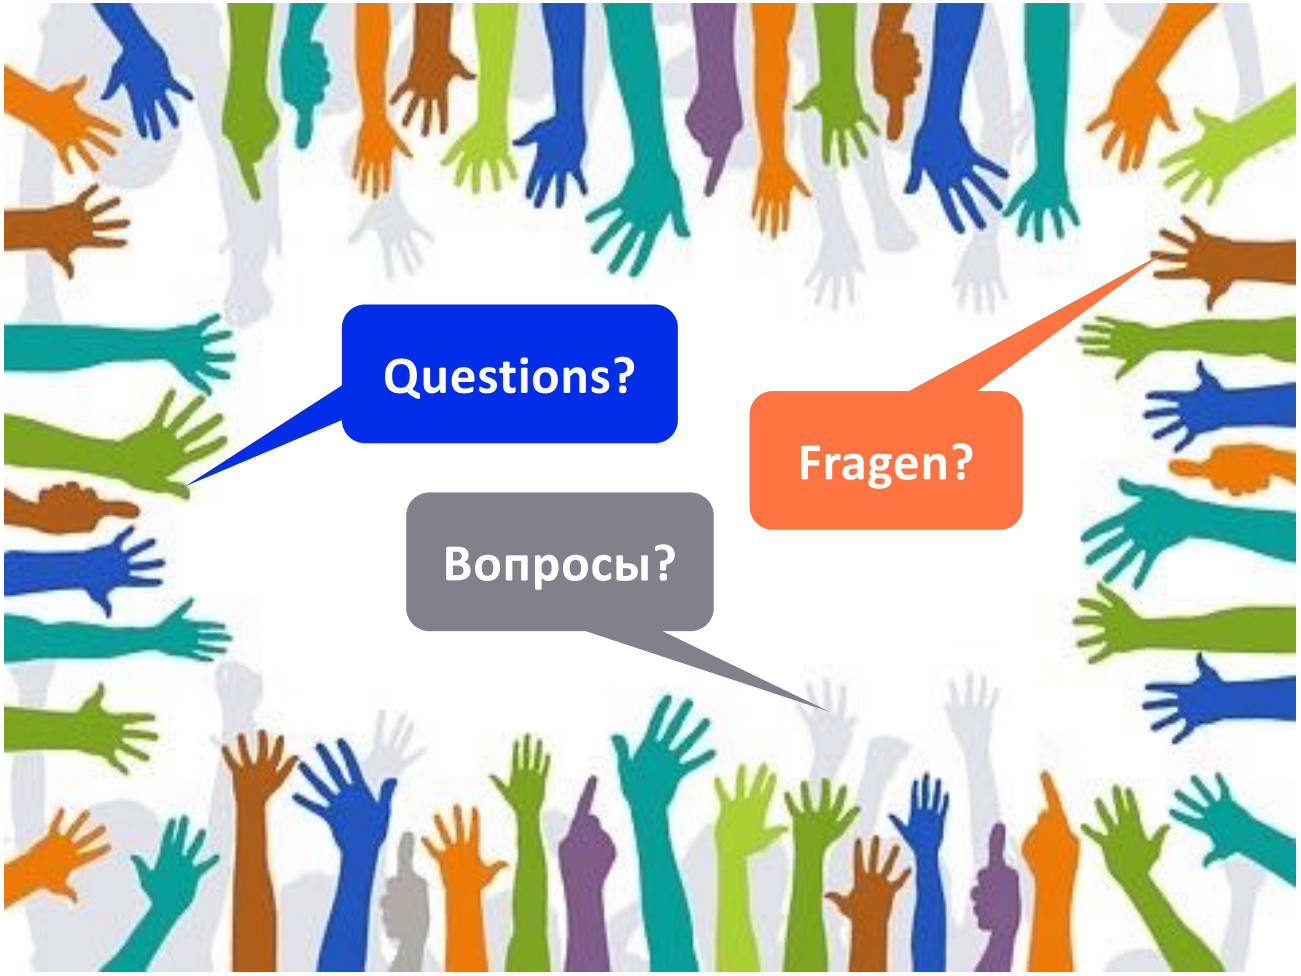


Шаг 1: Сбор и подготовка документов
Шаг 2: Предобработка текстов (разбиваем документы на предложения или абзацы, приводим текст к нижнему регистру, удаляем стоп-слова, выполняем токенизацию, сохраняем обработанные тексты для дальнейшего использования)
Шаг 3: Построение поискового индекса (проводим векторизацию текстов)
Шаг 4: Получение вопроса от пользователя
Шаг 5: Обработка вопроса (очищаем вопрос от лишних символов, выполняем токенизацию вопроса, удаляем стоп-слова из вопроса, расширяем запрос синонимами ключевых слов)
Шаг 6: Поиск релевантных документов (ищем наиболее похожие документы для чего используем метрику (косинусное сходство, корреляцию и т.п.), выбираем наиболее релевантный документ)
Шаг 7: Формирование ответа (выводим ответ, если подходящих ответов не найдено, то готовим вежливый отказ с рекомендациями)

Оценка качества систем анализа текстов



$$Precision = \frac{\#relevant\ retrieved}{\#retrieved} = \frac{2}{4};\ Recall = \frac{\#relevant\ retrieved}{\#relevant} = \frac{2}{7};$$


Questions?
Fragen?
Вопросы?